



# Machine Learning 101

Boosted Trees




# ■ Introducción

- Una de las ideas más brillantes en machine learning de los últimos tiempos
- Proceso iterativo basado en la combinación lineal de algoritmos sencillos (*weak classifiers/regressors*)
- Aplicable a cualquier algoritmo de ML. Normalmente árboles (Boosted Trees)
- Mucha gente lo usa como banco de pruebas para pruebas de concepto



# Intuición




$$H(x) = \text{sign}(\alpha_1 h_1(x) + \alpha_2 h_2(x) + \alpha_3 h_3(x))$$



# Proceso iterativo

- En cada iteración le damos más peso a los errores




# ■ Hiperparámetros

- **Número de árboles** (iteraciones). Si es muy alto peligro de overfitting. Seleccionamos con validación cruzada
- **Tasa de aprendizaje** (Learning Rate, alpha). Número positivo de valor pequeño, normalmente 0.01, 0.001. Está relacionado con el número de iteraciones. Si alpha es pequeño, se necesitarán más iteraciones para que las prestaciones converjan
- **Profundidad del árbol**. Controlamos la complejidad del árbol. Idealmente interesa que sea pequeña, así la capacidad de generalización es mayor. Se recomienda comenzar con valores pequeños.



# ■ Interpretabilidad: *partial dependence plots*

- Efecto marginal de cada característica con variable target predicha (regresión)




[Scikit Learn Docs](https://scikit-learn.org/docs)



# ■ Interpretabilidad: *partial dependence plots*

- Efecto marginal de cada característica con variable target predicha (clasificación)



[Scikit Learn Docs](https://www.scikitlearn.org/)



# ■ Implementaciones

- sklearn: [Gradient Boosting](#)
- [XGBoost](#)
- [LightGBM](#)





# ■ Árboles de decisión (*tree-based models*)

- Relaciones no lineales
- Sin necesidad de escalar variables
- Árbol aislado, muy interpretable (si no es muy profundo)
- Random Forest, algoritmo muy robusto, es un buen benchmark
- Mejores prestaciones, si se eligen con cuidado los parámetros libres
  - La potencia sin control no sirve de nada



# ■ Referencias

- The Elements of Statistical Learning.
  - Capítulo 10
- Introduction to Statistical Learning.
  - Capítulo 8, sección 3



Let's code!

